

元编程与Pytorch编程

23020007073 刘畅

2024 年 9 月 17 日

1 实验目的

本次课程主要掌握代码的调试及性能分析、元编程和Pytorch编程。

2 练习内容

2.1 调试及性能分析样例8个

1.pdb断点的使用

```
import pdb
def add(a, b):
    pdb.set_trace() # 设置断点
    return a + b
result = add(8, 9)
print("Result:", result)
```

断点操作如下:

- l (或list): 列出当前执行点周围的代码。
- n (或next): 执行当前行, 并停在下一行。
- s (或step): 进入函数内部。
- c (或continue): 继续执行程序, 直到下一个断点。
- q (或quit): 退出调试器。
- p (或print): 打印表达式的值。
- pp: 以更可读的格式打印表达式的值。
- b (或break): 设置断点, 例如b 10在第十行设置断点。
- clear: 清除一个或所有断点。
- a (或args): 打印当前函数的参数。
- r (或return): 执行函数直到返回。
- j (或jump): 跳转到指定行。
- w (或where): 打印当前堆栈跟踪。

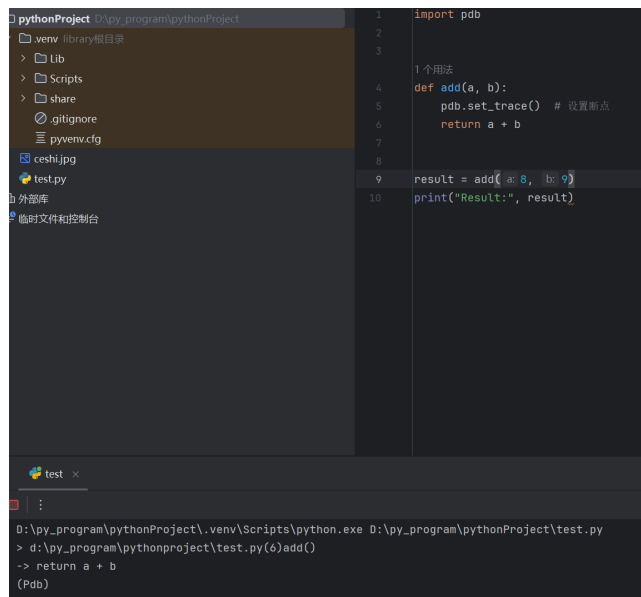


图 1: pdb断点的设置

2.assert的使用

```

def add_positive_numbers(a, b):
    assert a > 0 and b > 0, "Both numbers must be positive"
    return a + b
# 调试情况，将触发断言错误
print(add_positive_numbers(-1, 2))
# 正常情况
print(add_positive_numbers(1, 2))

```

```

AssertionError: Both numbers must be positive

```

图 2: assert的使用

3.使用日志记录调试

```

import logging
logging.basicConfig(level=logging.DEBUG)
def divide(a, b):
    logging.debug(f"Dividing {a} by {b}")
    try:
        result = a / b
    except ZeroDivisionError:
        logging.error("Division by zero!")
        return None
    logging.debug(f"Result is {result}")

```

```

return result

print(divide(15, 3))
print(divide(15, 0))

```

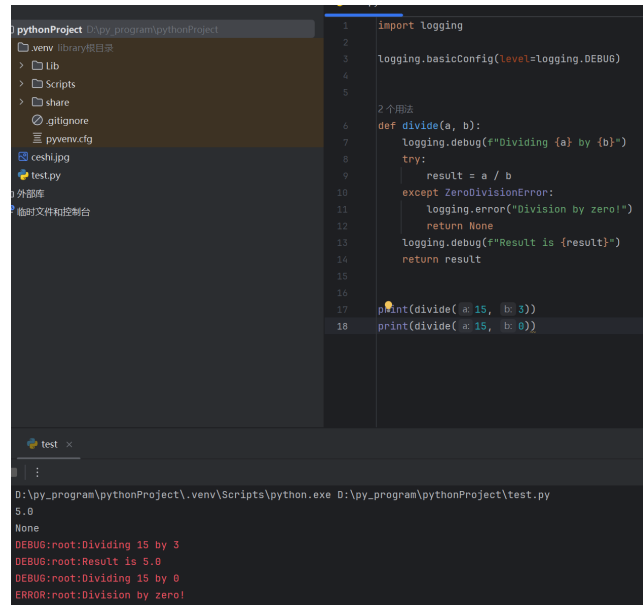


图 3: 日志记录调试

4.

当函数抛出异常时，`traceback.print_exc()`会打印出异常的堆栈跟踪，帮助定位问题。

```

import traceback
def cause_error():
    return 1 / 0
try:
    cause_error()
except Exception:
    traceback.print_exc()

```

```
ZeroDivisionError: division by zero
```

图 4: traceback模块打印异常信息

5.

使用memory_profiler模块来分析函数内存使用情况

```

from memory_profiler import profile
@profile
def create_large_list():
    large_list = [0] * int(1e7)

```

```

return large_list
create_large_list()

```

Line #	Mem usage	Increment	Occurrences	Line Contents
=====				
3	23.3 MiB	23.3 MiB	1	@profile
4				def performance_function():
5	23.3 MiB	0.0 MiB	1	result = 0
6	23.3 MiB	0.0 MiB	1000001	for i in range(1000000):
7	23.3 MiB	0.0 MiB	1000000	result += i
8	23.3 MiB	0.0 MiB	1	return result

图 5: 结果如图

6.

这段代码通过cProfile模块记录并分析了example_function的运行时间，然后使用pstats模块打印出了性能分析的结果。

```

import cProfile
import pstats

def example_function():
    total = 0
    for i in range(1000):
        total += i
    return total

# 使用cProfile运行函数并保存性能数据
profiler = cProfile.Profile()
profiler.enable()
example_function()
profiler.disable()

# 打印性能分析结果
stats = pstats.Stats(profiler).sort_stats('cumtime')
stats.print_stats()

```

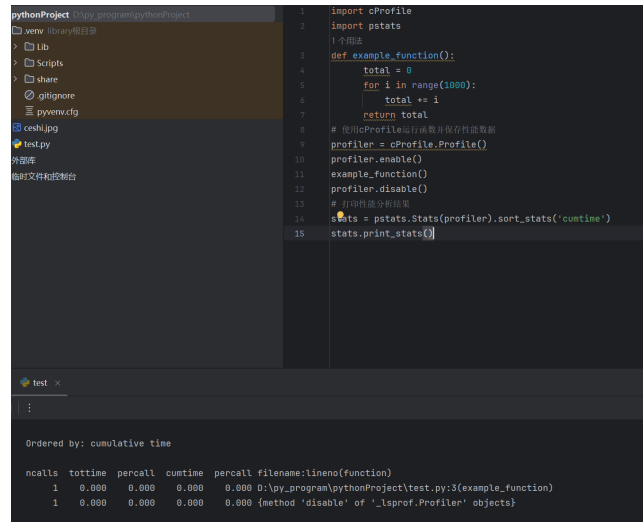


图 6: cProfile进行性能分析

7.

用start_time和end_time记录时间

```

import time
start_time = time.time()
squares = []
for i in range(1000):
    squares.append(i**2)
end_time = time.time()
print(f"Using loop: {end_time - start_time} seconds")

```




图 7: time进行时间记录

8.

用timeit重复运行函数并计算平均运行时间

```

import timeit
import logging
# 配置日志记录器
logging.basicConfig(level=logging.DEBUG, format='%(asctime)s - %(levelname)s - %(message)s')
def debug_example(x):
    logging.debug(f"Entering debug_example with argument: {x}")
    result = x * 2
    logging.debug(f"Exiting debug_example with result: {result}")
    return result
# 调用函数并观察日志输出
debug_example(10)

```

```
def performance_test():
    total = 0
    for i in range(1000):
        total += i
    return total

# 使用timeit重复运行函数并计算平均运行时间
execution_time = timeit.timeit('performance_test()', globals=globals(), number=1000)
print(f"Function performance_test executed 1000 times in {execution_time:.4f} seconds")
```

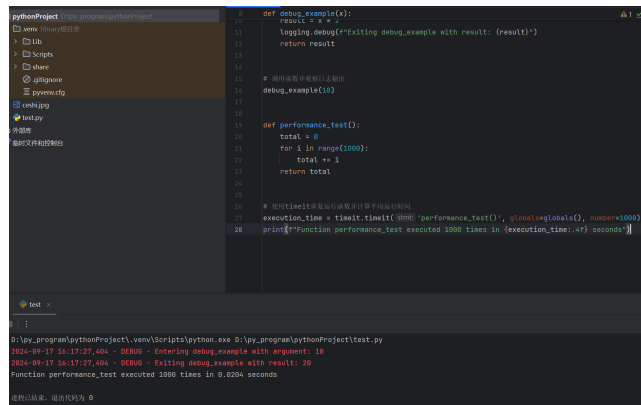


图 8: timeit计算运行时间

2.2 元编程学习例子9个

1. 使用装饰器修饰函数

```
def debug(func):
    def wrapper(*args, **kwargs):
        print(f"Calling function: {func.__name__}")
        result = func(*args, **kwargs)
        print(f"Function {func.__name__} returned: {result}")
        return result
    return wrapper

@debug
def add(a, b):
    return a + b

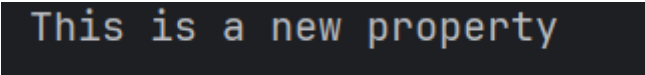
# 调用装饰过的函数
add(1, 6)
```

```
Calling function: add
Function add returned: 7
```

图 9: 调用装饰过函数后的结果

2.使用装饰器修饰类

```
def add_property(cls):
    cls.new_property = "This is a new property"
    return cls
@add_property
class MyClass:
    pass
# 检查新属性
print(MyClass.new_property)
```




This is a new property

图 10: 调用装饰过类后的结果

3.

使用__slots__限制对象属性

```
class MyClass:
    __slots__ = ['name']
def __init__(self, name):
    self.name = name
obj = MyClass('John')
obj.age = 30
print(obj.name)
print(obj.age)
```



AttributeError: 'MyClass' object has no attribute 'age'

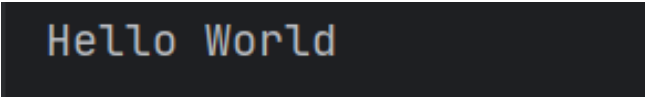
图 11: 限制对象属性输出结果

4.使用exec函数动态执行了一段包含函数定义的字符串代码，然后调用这个新定义的函数，并输出结果

```
code = "def hello(): print('Hello World')"
```

```
exec(code)
```

```
hello() # 输出: Hello World
```



Hello World

图 12: hello()输出后的结果

5.使用修饰器改变函数行为

```
from functools import wraps
def add_hello(func):
```

```

@wraps(func)
def wrapper(*args, **kwargs):
    print("Hello")
    return func(*args, **kwargs)
return wrapper
@add_hello
def say_goodbye():
    print("Goodbye")
say_goodbye()

```

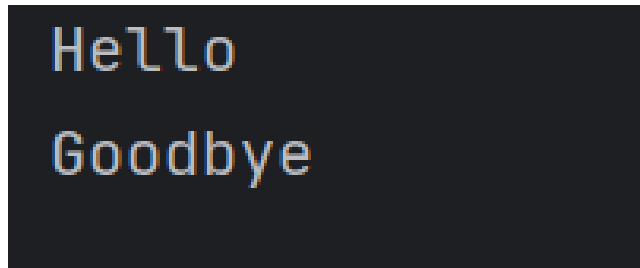


图 13: 使用修饰器改变函数行为

6.

使用Python的内置函数type来动态创建一个类

```

def create_class(name, bases, attrs):
    return type(name, bases, attrs)
MyClass = create_class('MyClass', (object,), {'x': 1})
print(MyClass)
print(MyClass.x)

```

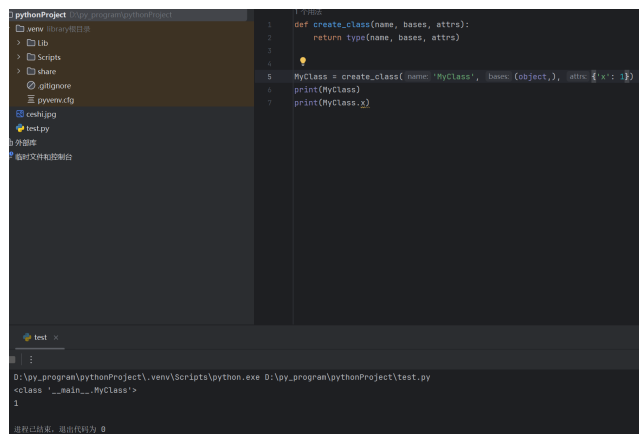


图 14: 用type动态创建一个类

7.

用functools.partial创建部分函数应用

```
from functools import partial
```



```
def multiply(x, y):
    return x * y
double = partial(multiply, 3)
print(double(4))
```

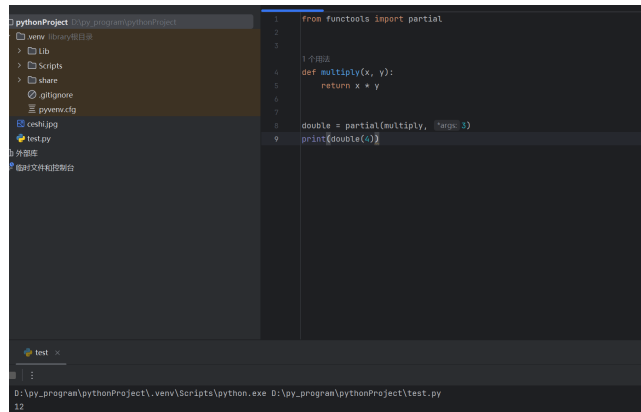


图 15: 用functools.partial创建部分函数应用

8.

```
class MyCallable:
def __init__(self, value):
    self.value = value
def __call__(self):
    print(self.value)
callable_obj = MyCallable("Hello")
callable_obj()
```




图 16: 输出结果:

9.

动态属性访问: 使用`__getattr__`和`__setattr__`可以拦截对属性的访问和赋值。
由于`__getattr__`魔术方法的存在, 即使`name`和`age`在`DynamicAttributes`类中没有定义, 这些属性也会从`kwargs`字典中获取, 并正确返回。

```
class DynamicAttributes:
def __init__(self, **kwargs):
    self.kwargs = kwargs
def __getattr__(self, attr):
```

```

return self.kwargs.get(attr, None)
obj = DynamicAttributes(name='lihua', age=20)
print(obj.name)
print(obj.age)

```

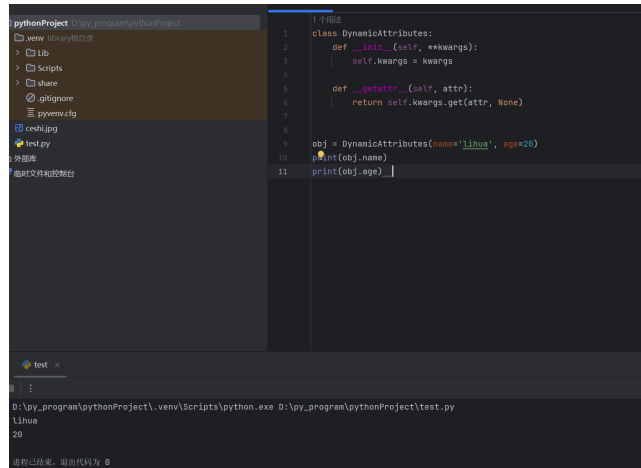


图 17: 元编程动态属性访问

2.3 Pytorch简单学习例子3个

1.张量的使用

```

import torch
# 创建一个张量
a = torch.tensor([1, 2, 3])
print(a)
# 加法操作
b = torch.tensor([4, 5, 6])
sum_ab = a + b
print(sum_ab)
# 乘法操作
product_ab = a * b
print(product_ab)

```

```

tensor([1, 2, 3])
tensor([5, 7, 9])
tensor([ 4, 10, 18])

```

图 18: 张量的使用

2.用Pytorch建立网络

```

import torch.nn as nn

```

```

import torch.nn.functional as F

# 定义一个网络
class Net(nn.Module):

    def __init__(self):
        super(Net, self).__init__()
        # 定义网络层
        self.conv1 = nn.Conv2d(1, 6, 3) # 输入通道1, 输出通道6, 3x3卷积核
        self.conv2 = nn.Conv2d(6, 16, 3)
        # 定义全连接层
        self.fc1 = nn.Linear(16 * 6 * 6, 120) # 6*6从图像维度推断
        self.fc2 = nn.Linear(120, 84)
        self.fc3 = nn.Linear(84, 10)

    def forward(self, x):
        # 在网络前向传播过程中定义数据流
        x = F.max_pool2d(F.relu(self.conv1(x)), (2, 2))
        x = F.max_pool2d(F.relu(self.conv2(x)), 2)
        x = x.view(-1, self.num_flat_features(x))
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        x = self.fc3(x)
        return x

    def num_flat_features(self, x):
        size = x.size()[1:] # 除去批处理维度的其他所有维度
        num_features = 1
        for s in size:
            num_features *= s
        return num_features

net = Net()
print(net)

```

```

Net(
  (conv1): Conv2d(1, 6, kernel_size=(3, 3), stride=(1, 1))
  (conv2): Conv2d(6, 16, kernel_size=(3, 3), stride=(1, 1))
  (fc1): Linear(in_features=576, out_features=120, bias=True)
  (fc2): Linear(in_features=120, out_features=84, bias=True)
  (fc3): Linear(in_features=84, out_features=10, bias=True)
)

```

图 19: 网络建立后的结果

3.用Pytorch对值进行预测

```

import torch
import torch.nn as nn
import torch.optim as optim
# 定义一个简单的线性回归模型
class LinearRegressionModel(nn.Module):
    def __init__(self, input_dim, output_dim):
        super(LinearRegressionModel, self).__init__()
        # 定义一个线性层，即矩阵乘法层
        self.linear = nn.Linear(input_dim, output_dim)

    def forward(self, x):
        # 应用线性层，即执行矩阵乘法
        out = self.linear(x)
        return out

# 设置输入和输出的维度
input_dim = 1 # 假设我们只有一个特征
output_dim = 1 # 假设我们预测一个值
# 实例化模型
model = LinearRegressionModel(input_dim, output_dim)
# 定义损失函数和优化器
criterion = nn.MSELoss() # 均方误差损失函数
optimizer = optim.SGD(model.parameters(), lr=0.01) # 随机梯度下降优化器
# 生成一些随机数据来模拟训练过程
# 假设我们的数据集是  $y = 2x + 1$ 
x_train = torch.randn(100, input_dim) # 100个样本，每个样本一个特征
y_train = 2 * x_train + 1 # 真实值
# 训练模型
num_epochs = 1000 # 训练的轮数
for epoch in range(num_epochs):
    # 前向传播
    outputs = model(x_train)

```

```

# 计算损失
loss = criterion(outputs, y_train)

# 清零梯度
optimizer.zero_grad()

# 反向传播和优化
loss.backward()
optimizer.step()

if (epoch + 1) % 100 == 0:
    print(f'Epoch [{epoch + 1}/{num_epochs}], Loss: {loss.item():.4f}')

# 测试模型
with torch.no_grad(): # 在这个上下文中，不需要计算梯度
    predicted = model(x_train).data.numpy() # 获得预测值
    actual = y_train.data.numpy() # 获得真实值
    print(f'Predicted: {predicted[:5]}')
    print(f'Actual: {actual[:5]}')

```

```

Predicted: [[-1.1923618 ]
 [ 2.1826167 ]
 [ 2.1387043 ]
 [ 3.0322967 ]
 [ 0.57764614]]
Actual: [[-1.1923635]
 [ 2.1826196]
 [ 2.1387072]
 [ 3.0323005]
 [ 0.5776468]]

```

图 20: 预测和真实结果

3 解题感悟

代码调试和性能分析让我高效率的解决了代码的问题这些技能提升了我的编程能力，也使我明白了持续优化和创新的重要性。

元编程让我意识到，代码可以是一种可以动态变化、自我进化的实体。

PyTorch的动态计算图能够让我轻松地构建和调试复杂的神经网络。这就是深度学习的强大。

github路径您可以在这里查看项目的源代码:

<https://github.com/L-c-hang/home4>